

Examen S2 : projet transverse

Classe : CPDIA 2 – ESIS 2

Noms/Prénoms :

Celia SAIDANI (ESIS2 - CPID)

Sofiane MAHMOUDI (ESIS2 - ILDE)

Sabrina BOUZEKRI (CPDIA 2- Data Analyst)

Aboubacar DIARRA (ESIS2-CIC)

Mohamed Ryad SMAILI (CPDIA2 – Data Analyst)

Rapport Volet B – Data Analyst

Programme Néovolt Grid+

1. Objectif du volet Data Analyst

Le rôle du volet Data Analyst dans le programme Néovolt Grid+ est de transformer les données brutes mises à disposition par Néovolt en informations exploitables pour les décideurs métier.

L'objectif n'est pas uniquement de produire des graphiques, mais de construire une lecture claire des données afin d'aider :

- L'exploitation réseau à mieux anticiper les pics de consommation et les zones sensibles ;
- La direction financière à mieux comprendre les volumes de consommation et les sources potentielles de pertes ;
- La relation client à suivre les réclamations et la satisfaction ;
- La DSI à améliorer la qualité, la gouvernance et la fiabilité des données.

Le travail réalisé couvre donc :

- L'exploration et la qualité des données ;
- Le nettoyage et la préparation ;
- L'analyse descriptive et multivariée ;
- L'analyse temporelle et météorologique ;
- L'analyse des incidents réseau ;

- L'analyse des profils horaires ;
- L'analyse descriptive des réclamations clients ;
- La préparation d'un dashboard Power BI décisionnel.

2. Données utilisées

Les fichiers CSV fournis dans le dossier « donnees » ont été chargés et contrôlés dans le notebook d'exploration.

Les fichiers principalement utilisés pour le volet Data Analyst sont :

Fichier	Utilisation
releves_consommation.csv	Base principale de l'analyse : consommation quotidienne par point de livraison
compteurs.csv	Enrichissement avec les caractéristiques des compteurs : zone, type client, puissance, chauffage
clients.csv	Enrichissement avec le segment client, la commune, la surface et la taille du foyer
meteo.csv	Analyse du lien entre consommation, température et degrés-jour de chauffage
incidents_reseau.csv	Analyse des incidents par zone, type, cause et impact réseau
releves_horaires_echantillon.csv	Analyse des profils horaires et des heures de pointe
reclamations.csv	Analyse relation client : canaux, satisfaction, volume de réclamations
cas_fraude_confirmeres.csv	Éclairage complémentaire sur les fraudes confirmées

Les fichiers **actifs_si.csv** et **journaux_securite.csv** ont été chargés dans le diagnostic global, mais ils relèvent principalement du volet cybersécurité. Ils n'ont donc pas été analysés en profondeur dans le volet Data Analyst.

3. Préparation et qualité des données

Un premier notebook, **01_exploration_qualite.ipynb**, a été réalisé afin d'évaluer la qualité des fichiers avant toute transformation.

Les contrôles réalisés portent sur :

- Le nombre de lignes et de colonnes ;
- Les types de données détectés ;
- Les valeurs manquantes ;
- Les doublons complets ;
- Les doublons métier ;
- Les plages de dates ;
- Les incohérences possibles sur les clés ;
- Les premières valeurs aberrantes de consommation.

Le fichier principal **releves_consommation.csv** contient plus de 500 000 lignes. Il constitue donc le cœur du travail d'analyse. Les contrôles ont montré qu'il fallait être prudent avant d'utiliser directement la donnée brute, car certaines consommations sont manquantes, négatives ou fortement atypiques.

Cette étape a permis de confirmer que les données sont exploitables, mais qu'elles nécessitent un nettoyage documenté avant analyse et restitution décisionnelle.

4. Nettoyage et préparation des données

Le notebook **02_nettoyage_preparation.ipynb** a permis de produire des fichiers préparés dans le dossier **data_cleaned**.

La stratégie de nettoyage retenue est volontairement prudente :

- Les données brutes ne sont jamais modifiées ;
- Les doublons métier sont supprimés uniquement lorsqu'ils concernent une même clé fonctionnelle ;
- Les dates sont converties dans un format exploitable ;
- Les variables numériques sont converties proprement ;
- Les consommations négatives sont identifiées comme non valides ;
- Les valeurs aberrantes sont repérées avec une méthode IQR ;
- Une colonne de consommation nettoyée est créée ;
- Les anomalies restent traçables grâce à des indicateurs de qualité.

La colonne **consommation_kwh_clean** a été créée pour les analyses. Elle conserve une logique de correction documentée :

- Les valeurs manquantes, négatives ou très aberrantes sont mises de côté ;
- Les imputations sont faites par médiane lorsque cela est possible ;

- Un indicateur **flag_conso_imputee** permet d'identifier les lignes corrigées.

Les données de consommation ont ensuite été enrichies avec :

- Les informations compteurs ;
- Les informations clients ;
- Les données météo ;
- Les variables temporelles : année, mois, jour, saison, week-end ;
- Les indicateurs météo comme les degrés-jour de chauffage.

Cette approche permet de produire des analyses exploitables tout en conservant la traçabilité des corrections.

5. Analyses principales

5.1 Consommation globale et saisonnalité

L'analyse mensuelle montre que la consommation varie dans le temps, avec des effets saisonniers. Les périodes froides sont associées à une consommation plus élevée, ce qui est cohérent avec les usages de chauffage.

Cette saisonnalité est importante pour Néovolt, car elle permet :

- D'anticiper les périodes de forte demande ;
- D'améliorer la préparation de l'exploitation réseau ;
- De mieux planifier les achats d'énergie ;
- De réduire les achats d'urgence en période de pointe.



5.2 Analyse par zone

La consommation a été analysée par zone géographique. Cette analyse permet d'identifier les zones les plus consommatrices et donc potentiellement les plus sensibles lors des pics de demande.

Il faut toutefois interpréter ces résultats avec prudence : une zone peut consommer davantage parce qu'elle compte plus de points de livraison, plus de clients professionnels ou davantage d'activités industrielles.

Cette lecture est utile pour :

- Prioriser les zones à surveiller ;
- Orienter la maintenance ;
- Préparer les vues exploitation réseau ;
- Croiser consommation, incidents et météo.

5.3 Analyse par type de client, segment et chauffage

Les consommations diffèrent selon :

- Le type de client ;
- Le segment commercial ;
- Le type de chauffage ;
- La puissance souscrite.

Les clients professionnels et industriels peuvent présenter des niveaux de consommation plus élevés que les clients résidentiels. Le type de chauffage est également une variable importante, en particulier pour les clients chauffés à l'électricité, dont la consommation est plus sensible aux températures froides.

Ces analyses sont utiles pour :

- La direction financière, afin de mieux comprendre les volumes par segment ;
- L'exploitation réseau, afin de suivre les profils les plus consommateurs ;
- La relation client, afin d'adapter les messages et services selon les usages.


5.4 Influence de la météo

L'analyse météo montre une relation importante entre température et consommation.

Les degrés-jour de chauffage ont été calculés afin de mesurer l'intensité du froid. Plus les degrés-jour augmentent, plus la journée est froide. L'analyse montre que les journées froides sont associées à des consommations plus élevées.

La relation observée confirme que la météo est un facteur explicatif majeur de la consommation. Cependant, la dispersion des points montre que la météo n'explique pas tout. D'autres facteurs doivent être pris en compte :

- Zone géographique ;
- Type de client ;
- Type de chauffage ;
- Jours ouvrés ou week-end ;
- Incidents réseau ;
- Qualité et complétude des données.





5.5 Analyse des incidents réseau

Les incidents réseau ont été analysés selon :

- La zone ;
- Le type d'incident ;
- La cause ;
- La durée ;
- Le nombre de points de livraison impactés.

Cette analyse permet d'identifier les zones et causes les plus fréquentes. Elle peut aider Néovolt à prioriser les actions de maintenance et de surveillance.

Le croisement entre consommation et incidents permet d'identifier les couples date/zone à surveiller. Toutefois, cette analyse reste descriptive : elle ne démontre pas qu'une forte consommation cause directement un incident. Un incident peut aussi provenir d'une panne matérielle, d'intempéries, d'une maintenance programmée ou d'un défaut réseau.



5.6 Analyse des profils horaires

Le fichier **relevés_horaires_echantillon.csv** a permis d'analyser un échantillon horaire.


L'objectif est d'identifier :


- Les heures de pointe ;
- Les différences entre jours ouvrés et week-ends ;
- Les profils moyens par heure ;

- Les variations par zone.

Cette analyse montre l'intérêt de suivre les courbes de charge à un pas plus fin que le quotidien. Elle peut aider l'exploitation réseau à anticiper les créneaux horaires critiques.

Cette partie doit néanmoins être interprétée avec prudence, car le fichier horaire ne couvre qu'un échantillon limité de points de livraison sur une période courte. Il ne faut donc pas généraliser directement ces résultats à l'ensemble du parc Néovolt.






5.7 Analyse des réclamations clients



Les réclamations ont été analysées de manière descriptive :

- Volume total ;
- Évolution mensuelle ;
- Canaux utilisés ;
- Satisfaction moyenne ;
- Clients les plus récurrents.

Cette analyse permet d'ajouter une lecture relation client au dashboard. Elle peut être utile pour identifier les périodes ou canaux générant davantage d'insatisfaction.

L'analyse reste descriptive, car les thèmes des réclamations ne sont pas encore étiquetés automatiquement. Une amélioration future serait d'utiliser du traitement automatique du langage naturel pour faire émerger les thèmes principaux : facturation, coupure, compteur, raccordement, qualité de service.





6. Dashboard Power BI

Un dashboard Power BI a été préparé à partir de fichiers agrégés powerbi_*.csv.

La stratégie retenue est volontairement légère :

- Ne pas importer directement le fichier complet consommation_preparee.csv, trop volumineux ;
- Utiliser des tables agrégées adaptées aux décideurs ;
- Construire des vues lisibles par profil métier.

Les dashboards :

[Projet Neovolt Dashboard.pbix](#)

7. Recommandations métier

Les analyses conduisent aux recommandations suivantes :

Recommandation 1 – Mettre en place un pilotage mensuel et saisonnier de la consommation

Néovolt doit suivre la consommation dans le temps afin d’anticiper les pics, notamment en période froide. Les variations mensuelles et saisonnières doivent être intégrées dans les tableaux de bord d’exploitation et dans les décisions d’achat d’énergie.

Recommandation 2 – Intégrer la météo au pilotage opérationnel

Les degrés-jour de chauffage constituent un indicateur utile pour anticiper les hausses de consommation. Néovolt devrait intégrer la température et les degrés-jour dans ses analyses régulières et dans les futurs modèles de prévision.

Recommandation 3 – Surveiller les zones fortement consommatrices

Les zones les plus consommatrices doivent être suivies plus finement, notamment lorsqu’elles cumulent forte consommation et incidents réseau. Cela peut aider à prioriser les actions de maintenance ou de renforcement réseau.

Recommandation 4 – Suivre les incidents par zone, type et cause

Une vue dédiée aux incidents permettrait à l’exploitation réseau de mieux identifier les causes récurrentes et de prioriser les interventions. Les causes liées à la vétusté, aux intempéries ou aux surcharges doivent être suivies séparément.

Recommandation 5 – Exploiter les profils horaires pour identifier les heures de pointe

Même si l’échantillon horaire est limité, il démontre l’intérêt de suivre les courbes de charge. Néovolt pourrait généraliser cette analyse pour anticiper les créneaux horaires critiques.

Recommandation 6 – Ajouter une vue relation client

Les réclamations et la satisfaction doivent être suivies dans le même dispositif de pilotage. Cela permet de relier les incidents, la consommation, les zones et la perception client.

Recommandation 7 – Renforcer la qualité et la gouvernance des données

Les anomalies détectées montrent la nécessité de mettre en place des règles de qualité régulières :

- Contrôle des doublons ;
- Contrôle des valeurs manquantes ;
- Contrôle des consommations négatives ;
- Suivi des valeurs imputées ;
- Documentation des traitements ;
- Responsabilisation des propriétaires de données.

8. Limites et précautions

Les résultats doivent être interprétés avec prudence.

Les principales limites sont :

- Les analyses sont descriptives et ne prouvent pas de causalité ;
- Le fichier horaire ne couvre qu'un échantillon limité ;
- Les consommations nettoyées reposent sur des règles d'imputation ;
- Les fraudes confirmées sont peu nombreuses ;
- Les données clients et consommation sont sensibles ;
- Les résultats agrégés masquent parfois des différences individuelles ;
- Les tableaux de bord doivent être utilisés comme outils d'aide à la décision, et non comme systèmes de décision automatique.

Ces limites doivent être rappelées dans la soutenance afin de montrer une posture professionnelle et responsable.

9. Dimensions transverses

9.1 RGPD et protection des données

Les données de consommation sont des données personnelles, car elles peuvent révéler des habitudes de vie. L'analyse doit donc respecter des principes de minimisation et de proportionnalité.

Dans le volet Data Analyst, les résultats sont majoritairement présentés sous forme agrégée :

- Par zone ;
- Par mois ;
- Par segment ;
- Par type de client ;
- Par canal de réclamation.

Aucune décision défavorable à un client ne doit être prise uniquement à partir d'un indicateur ou d'un score. Toute analyse liée à la fraude ou à l'insatisfaction doit conserver une validation humaine.

9.2 Biais et équité

Les analyses par segment ou type de client peuvent être utiles, mais elles doivent être interprétées avec prudence. Un groupe de clients plus consommateur ne doit pas être considéré automatiquement comme suspect.

Les résultats doivent servir à orienter l'exploitation, la qualité de service et la maintenance, pas à stigmatiser certains profils.

9.3 Green IT et sobriété

Le choix technique a été de produire des fichiers agrégés pour Power BI plutôt que d'importer systématiquement le fichier complet de consommation.

Cette approche présente plusieurs avantages :

- dashboard plus léger ;
- Temps de chargement réduit ;
- Dépôt GitHub plus propre ;
- Réduction des traitements inutiles ;
- Meilleure reproductibilité.

9.4 Gouvernance des données

Le travail a mis en évidence l'importance de règles de gouvernance :

- Définir les propriétaires des données ;
- Documenter les règles de nettoyage ;
- Tracer les imputations ;
- Suivre la qualité dans le temps ;
- Limiter les accès aux données sensibles ;
- Distinguer données brutes et données préparées.

10. Conclusion

Le volet Data Analyst du projet Néovolt Grid+ a permis de transformer les fichiers bruts en analyses exploitables et en tableaux de bord décisionnels.

Les travaux réalisés montrent que les données de Néovolt permettent déjà de produire de la valeur :

- Meilleure compréhension des consommations ;
- Identification des zones et profils sensibles ;
- Analyse de la saisonnalité ;

- Mise en évidence du rôle de la météo ;
- Suivi des incidents réseau ;
- Analyse des profils horaires ;
- Suivi des réclamations et de la satisfaction.

Le dashboard Power BI constitue un prototype crédible pour aider les décideurs à piloter le programme.

La prochaine étape serait d'industrialiser les contrôles qualité, d'automatiser l'actualisation des données et d'intégrer les modèles prédictifs dans une plateforme data gouvernée, sécurisée et conforme.