

Examen S2 : projet transverse

Classe : CPDIA 2 – ESIS 2

Noms/Prénoms :

Celia SAIDANI (ESIS2 - CPID)

Sofiane MAHMOUDI (ESIS2 - ILDE)

Sabrina BOUZEKRI (CPDIA 2- Data Analyst)

Aboubacar DIARRA (ESIS2-CIC)

Mohamed Ryad SMAILI (CPDIA2 – Data Analyst)

Rapport Volet C – Data Scientist

Modèle de prévision de consommation – Programme Néovolt Grid+

1. Objectif du volet Data Scientist

Le volet Data Scientist du programme Néovolt Grid+ vise à construire un prototype de modèle prédictif permettant d'anticiper la consommation électrique totale journalière.

Le cas d'usage retenu est la **prévision de consommation**.

La détection d'anomalies ou de fraude n'a pas été traitée dans ce volet afin de concentrer le travail sur un modèle de prévision documenté, évalué et interprétable.

L'objectif métier est d'aider Néovolt à :

- Anticiper les pics de consommation ;
- Mieux préparer les achats d'énergie ;
- Limiter les achats d'énergie en urgence ;
- Améliorer la stabilité du réseau ;
- Fournir une aide à la décision aux équipes exploitation et finance.

Le modèle développé ne doit pas être considéré comme un système de décision automatique. Il s'agit d'un outil d'aide à la décision, destiné à éclairer les métiers, avec validation humaine obligatoire avant toute action critique.

2. Cas d'usage retenu

Le cas d'usage choisi est :

Prévoir la consommation électrique totale journalière de Néovolt à partir de l'historique de consommation, des variables calendaires et des données météorologiques.

La variable cible est : **consommation_totale_kwh**

La prévision est réalisée au niveau global journalier, et non au niveau client, compteur ou zone.

Ce choix est adapté au contexte du projet pour plusieurs raisons :

- Il répond directement au besoin métier d'anticipation de la demande globale ;
- Il limite la complexité du prototype ;
- Il réduit l'exposition des données personnelles ;
- Il permet une évaluation claire avec des métriques compréhensibles ;
- Il correspond à un premier niveau d'aide à la décision pour les achats d'énergie et l'exploitation réseau.

Ce modèle n'a donc pas vocation à prédire le comportement individuel d'un client. Il sert à anticiper la consommation globale du réseau à court terme.

3. Données utilisées

Le volet Data Scientist s'appuie sur les données nettoyées et enrichies produites dans le volet Data Analyst.

Le fichier de départ utilisé est :

volet-b-data-analyst/data_cleaned/consommation_preparee.csv

Ce fichier contient :

- Les relevés de consommation nettoyés ;
- Les informations compteurs ;
- Les informations clients ;
- Les données météorologiques ;
- Les variables temporelles ;
- Les indicateurs de qualité ;
- La consommation nettoyée consommation_kwh_clean.

À partir de ce fichier, un dataset spécifique à la prévision a été créé :

volet-c-data-scientist/outputs/dataset_forecast_journalier.csv

Ce dataset est agrégé au niveau journalier. Il est léger, reproductible et versionné dans GitHub.

4. Préparation du dataset de prévision

La préparation du dataset a été réalisée dans le notebook :

01_preparation_dataset_forecast.ipynb

Les données ont été agrégées par date afin d'obtenir une ligne par jour.

Le dataset final contient plusieurs familles de variables.

4.1 Variables de consommation

- consommation_totale_kwh : cible du modèle ;
- consommation_moyenne_kwh ;
- nb_relevés ;
- part_lignes_imputees_pct.

La variable cible consommation_totale_kwh représente la consommation totale observée sur une journée.

4.2 Variables météo

- temp_moyenne_c ;
- temp_min_c ;
- temp_max_c ;
- degres_jour_chauffage.

Les degrés-jour de chauffage mesurent l'intensité du froid. Plus cette valeur est élevée, plus la journée est froide. Cette variable est importante, car la consommation électrique est fortement influencée par les besoins de chauffage.

4.3 Variables calendaires

- Année ;
- Mois ;
- Jour ;
- Jour de semaine ;
- Week-end ;
- Jour de l'année ;
- Saison.

Ces variables permettent au modèle de capter les effets calendaires : saisonnalité, différence entre semaine et week-end, ou encore variations mensuelles.

4.4 Variables historiques

Pour capturer la dynamique temporelle, plusieurs variables de retard ont été créées :

- Conso_lag_1 : consommation de la veille ;
- Conso_lag_7 : consommation de la semaine précédente ;
- Conso_rolling_7 : moyenne mobile des 7 jours précédents ;
- Conso_rolling_14 : moyenne mobile des 14 jours précédents.

Ces variables sont importantes, car la consommation énergétique dépend fortement de l'historique récent. Par exemple, une journée froide est souvent entourée d'autres journées froides, ce qui crée une continuité dans les niveaux de consommation.

5. Séparation train/test

La séparation des données a été faite selon une logique temporelle :

Train : données avant le 01/10/2025

Test : données à partir du 01/10/2025

Cette séparation est essentielle dans un problème de prévision.

Un découpage aléatoire aurait été incorrect, car il aurait mélangé le passé et le futur.

L'objectif est de reproduire une situation réaliste : le modèle apprend sur l'historique disponible et il est évalué sur une période future non vue.

Cette méthode permet de tester la capacité réelle du modèle à prévoir la consommation sur une période à venir.

6. Modèles testés

La modélisation a été réalisée dans le notebook :

02_modelisation_prevision.ipynb

Trois approches ont été comparées.

6.1 Baseline naïve J-1

La baseline naïve prédit que la consommation du jour sera égale à celle de la veille.

Cette baseline est indispensable. Elle permet de répondre à une question simple :

Le modèle de machine learning fait-il mieux qu'une règle très simple ?

Si un modèle avancé ne bat pas cette baseline, il n'apporte pas de valeur suffisante.

6.2 Régression Ridge

La Régression Ridge est un modèle linéaire régularisé.

Elle cherche à modéliser la consommation comme une combinaison pondérée des variables explicatives : météo, calendrier, consommation passée, moyennes mobiles, saisonnalité.

La régularisation limite les coefficients trop extrêmes et réduit le risque de surapprentissage.

Ce modèle est pertinent dans ce projet pour plusieurs raisons :

- il est simple ;
- il est rapide à entraîner ;
- il est plus interprétable qu'un modèle complexe ;
- il fonctionne bien sur un dataset agrégé ;
- il est adapté à un prototype opérationnel ;
- il est plus facile à expliquer à un comité de pilotage.

6.3 Random Forest Regressor

Le Random Forest est un modèle non linéaire basé sur un ensemble d'arbres de décision.

Il peut capter des relations plus complexes entre les variables, mais il présente aussi des limites :

- il est moins interprétable qu'un modèle linéaire ;
- il peut être plus sensible au surapprentissage ;
- il est plus difficile à expliquer à des décideurs non techniques ;
- il est plus lourd à maintenir en production.

Il a été testé pour vérifier si un modèle non linéaire apportait une amélioration significative.

7. Métriques d'évaluation

Les modèles ont été évalués avec trois métriques.

7.1 MAE – Mean Absolute Error

La MAE mesure l'erreur absolue moyenne en kWh.

Elle est très utile pour les métiers, car elle répond directement à la question :

En moyenne, de combien de kWh le modèle se trompe-t-il par jour ?

C'est la métrique principale retenue pour choisir le meilleur modèle.

7.2 RMSE – Root Mean Squared Error

La RMSE pénalise davantage les grosses erreurs.

Elle est importante dans le contexte de Néovolt, car une grosse erreur de prévision peut avoir un impact opérationnel plus important qu'une petite erreur régulière.

7.3 MAPE – Mean Absolute Percentage Error

Le MAPE exprime l'erreur moyenne en pourcentage.

Il permet d'avoir une lecture relative de la performance, plus facile à communiquer à des décideurs.

8. Résultats et choix du modèle

Les métriques obtenues sont stockées dans :

outputs/model_forecast_metrics.csv


Après comparaison des modèles, le meilleur modèle retenu est : **Régression Ridge**

Le choix de **Ridge** n'est pas uniquement basé sur le fait qu'il fonctionne. Il repose sur plusieurs critères :

8.1 Performance

La Régression Ridge obtient la meilleure performance selon la métrique principale retenue, la MAE.

Cela signifie qu'en moyenne, sur la période de test, Ridge produit les erreurs de prévision les plus faibles parmi les modèles comparés.



Cette capture doit montrer le graphique de comparaison des modèles selon la MAE.

8.2 Comparaison avec la baseline

Ridge doit être comparé à la baseline naïve J-1.

Le fait que Ridge obtienne une meilleure MAE que la baseline montre qu'il apporte une vraie valeur ajoutée. Il ne se contente pas de recopier la consommation de la veille : il exploite aussi les variables météo, calendaires et historiques.

8.3 Comparaison avec Random Forest

Random Forest est plus complexe, mais il n'a pas été retenu comme meilleur modèle.

Cela montre qu'un modèle plus complexe n'est pas forcément meilleur. Dans ce cas, la structure des données semble suffisamment bien captée par un modèle linéaire régularisé.

Ce résultat est intéressant pour Néovolt, car il favorise un modèle : plus simple à expliquer, plus rapide à entraîner, plus facile à maintenir, moins coûteux en calcul, plus acceptable dans un contexte d'aide à la décision.

8.4 Justification du choix final

La Régression Ridge est donc retenue car elle présente le meilleur compromis entre :

- Performance ;
- Simplicité ;
- Robustesse ;
- Interprétabilité ;
- Sobriété de calcul ;
- Facilité de mise en production.

Dans une infrastructure critique, ce compromis est préférable à un modèle plus complexe mais plus difficile à comprendre et à contrôler.


9. Ce que vaut réellement le modèle Ridge

Le modèle Ridge ne doit pas être évalué uniquement par son existence ou par une courbe visuellement satisfaisante.

Son évaluation repose sur :

- La comparaison avec une baseline ;
- Les métriques MAE, RMSE et MAPE ;
- L'analyse des prédictions sur une période future ;
- L'analyse des erreurs jour par jour ;
- L'identification des périodes où il se trompe davantage.

La comparaison réel/prédit permet de vérifier si le modèle suit bien la dynamique de consommation sur la période de test.



Interprétation

Lorsque les courbes réelle et prédite sont proches, cela signifie que le modèle suit correctement l'évolution globale de la consommation.

Cependant, même si les courbes se superposent fortement, cela ne suffit pas pour conclure que le modèle est parfait. Il faut aussi analyser les erreurs.

10. Analyse des erreurs

L'évaluation détaillée a été réalisée dans :

03_evaluation_interpretation.ipynb


L'analyse des erreurs permet de comprendre où et comment le modèle se trompe.

Une erreur est calculée comme :

$\text{erreur} = \text{consommation réelle} - \text{consommation prédite}$

Donc :

- Une erreur positive signifie que le modèle a sous-estimé la consommation ;
- Une erreur négative signifie que le modèle a surestimé la consommation.



Cette capture doit montrer le graphique des erreurs journalières.

10.1 Pourquoi cette analyse est importante


Dans une infrastructure énergétique, la moyenne des erreurs ne suffit pas.

Il faut regarder les jours où les erreurs sont les plus fortes, car ce sont ces journées qui peuvent poser problème pour l'exploitation.

Une erreur faible en moyenne peut cacher quelques jours très mal prédits. Or ces jours peuvent correspondre à des pics ou à des situations critiques.

11. Analyse des erreurs par période

Les erreurs ont également été analysées par mois et par jour de semaine.



Cette analyse permet de voir si le modèle est plus fragile à certaines périodes.

Par exemple :

- Une erreur plus forte en hiver pourrait indiquer une difficulté à modéliser les périodes froides ;
- Une erreur plus forte certains jours de semaine pourrait indiquer un effet calendrier mal capté ;
- Une erreur plus forte en période de changement météo pourrait indiquer un besoin de données météo plus fines.

12. Que se passe-t-il si le modèle se trompe ?

Cette question est centrale dans le cas Néovolt, car l'entreprise exploite une infrastructure critique.

Une erreur de prévision n'a pas seulement une conséquence statistique. Elle peut avoir un impact opérationnel, financier et potentiellement réseau.

12.1 Cas 1 – Le modèle sous-estime la consommation

Si le modèle prédit une consommation plus faible que la réalité, Néovolt peut sous-préparer ses achats d'énergie.

Conséquences possibles : achats d'énergie d'urgence, coût d'achat plus élevé, difficulté à anticiper un pic, tension accrue sur le réseau, moindre préparation des équipes exploitation.

Dans ce cas, le risque principal est opérationnel et financier.

12.2 Cas 2 – Le modèle surestime la consommation

Si le modèle prédit une consommation plus élevée que la réalité, Néovolt peut sur-préparer ses achats.

Conséquences possibles : achats d'énergie surdimensionnés, coûts inutiles, mauvaise allocation des ressources, perte de confiance dans l'outil de prévision.

Dans ce cas, le risque est surtout économique.

12.3 Cas 3 – Le modèle se trompe lors d'un pic

Le risque le plus critique est une erreur pendant une période de pointe.

Si le modèle sous-estime un pic de consommation, Néovolt peut ne pas anticiper suffisamment : les besoins énergétiques, les contraintes réseau, les équipes d'astreinte, les actions préventives.

C'est pour cette raison que le modèle ne doit jamais être utilisé seul pour piloter une infrastructure critique.

13. Pourquoi le modèle ne doit pas décider seul

Même si Ridge obtient les meilleures performances, le modèle doit rester une aide à la décision.

Il ne doit pas :

- Déclencher automatiquement des actions critiques ;
- Remplacer l'expertise des exploitants réseau ;
- Être connecté directement au SCADA ;
- Être utilisé sans supervision ;
- Être considéré comme fiable dans toutes les situations.

Le bon usage du modèle est le suivant :

Modèle → prévision → tableau de bord → analyse métier → décision humaine

Le modèle fournit un signal et la décision reste humaine.

14. Limites du modèle Ridge

14.1 Modèle global

Le modèle prédit la consommation totale journalière.

Il ne prédit pas la consommation : par zone, par compteur, par client, par segment.

Il donne donc une vision globale, mais ne permet pas encore un pilotage local fin.

14.2 Météo observée et non météo prévisionnelle

Le prototype utilise les données météo présentes dans le dataset. En production, il faudrait utiliser de vraies prévisions météo futures. C'est une limite importante, car un modèle opérationnel doit prédire le futur avec des informations réellement disponibles avant la journée à prévoir.

14.3 Données historiques limitées

Le modèle est entraîné sur deux années de données.

C'est suffisant pour un prototype, mais limité pour industrialiser un modèle robuste.

Il faudrait tester le modèle sur davantage d'années pour vérifier sa résistance à : des hivers plus froids, des étés plus chauds, des évolutions du parc client, des changements de comportement, des événements exceptionnels.

14.4 Variables externes absentes

Le modèle ne prend pas en compte certains facteurs : jours fériés, vacances scolaires, événements économiques, incidents majeurs, effacement énergétique, évolution tarifaire, changements de périmètre client.

Ces variables pourraient améliorer la prévision future.

14.5 Modèle linéaire

Ridge est un modèle linéaire. Il peut être moins performant si les relations entre variables deviennent fortement non linéaires.

Cependant, dans ce prototype, il offre le meilleur compromis entre performance et maîtrise.

15. Conditions de mise en production

Pour industrialiser ce modèle, plusieurs conditions doivent être remplies.

15.1 Pipeline de données automatisé

Il faudrait automatiser :

- L'ingestion des nouveaux relevés ;
- L'intégration des données météo ;
- Le nettoyage ;
- La création des variables ;
- La génération de la prévision ;
- L'export vers le tableau de bord.

15.2 Intégration de prévisions météo réelles

Le modèle devra utiliser des prévisions météo disponibles avant la journée à prédire, et non des températures observées a posteriori.

15.3 Monitoring des performances

Il faudra suivre régulièrement :

- MAE ;
- RMSE ;

- MAPE ;
- Erreurs en période froide ;
- Erreurs lors des pics ;
- Dérive de la consommation ;
- Dérive météo.

Si les performances se dégradent, le modèle devra être réentraîné.

15.4 Réentraînement régulier

Le modèle devrait être réentraîné :

- Chaque mois ;
- Après un changement important du parc client ;
- Après une évolution des comportements ;
- Après une dégradation des métriques ;
- Après ajout de nouvelles variables explicatives.

15.5 Validation humaine

Toute prévision critique doit être validée par un responsable métier.

Le modèle doit alimenter un dashboard ou un outil d'aide à la décision, mais pas piloter automatiquement le réseau.

16. Éléments MLOps

Une démarche MLOps minimale est nécessaire pour rendre le modèle exploitable dans le temps.

16.1 Versioning

Il faut versionner :

- Le code ;
- Les notebooks ;
- Les datasets préparés ;
- Les variables utilisées ;
- Les métriques ;
- Les paramètres du modèle ;
- Les rapports d'évaluation.

16.2 Traçabilité

Chaque entraînement doit être traçable :

- Date d'entraînement ;

- Période de données utilisée ;
- Modèle testé ;
- Métriques obtenues ;
- Modèle retenu ;
- Limites identifiées.

17. Dimensions transverses

17.1 RGPD

Le modèle travaille à un niveau agrégé journalier.

Ce choix limite l'exposition de données personnelles par rapport à un modèle par client ou par compteur.

Cependant, les données de consommation restent sensibles. Les accès doivent être : limités, tracés, justifiés, sécurisés.

17.2 Biais

Le modèle peut être moins performant sur certaines périodes ou certains profils si l'historique n'est pas représentatif. Il faut donc éviter de considérer la prévision comme une vérité absolue.

Le modèle doit être évalué régulièrement sur différentes périodes.

17.3 Green IT

Le choix de Ridge est cohérent avec une démarche de sobriété :

- Entraînement rapide ;
- Faible coût de calcul ;
- Pas de deep learning inutile;
- Dataset agrégé léger ;
- Modèle maintenable.

Cette approche est adaptée à un prototype réaliste et responsable.

17.4 Sécurité et infrastructure critique

Néovolt opère une infrastructure critique.

Le modèle ne doit pas être connecté directement à un environnement critique comme le SCADA sans : analyse de risque, contrôle d'accès, supervision, validation métier, journalisation, plan de secours.

Le modèle doit rester dans un environnement data maîtriser.

18. Conclusion

Le volet Data Scientist a permis de construire un prototype complet de prévision de consommation journalière pour Néovolt Grid+.

La démarche suivie répond aux exigences :

- Préparation d'un dataset de prévision ;
- Création de variables météo, calendaires et historiques ;
- Séparation temporelle train/test ;
- Comparaison avec une baseline ;
- Entraînement de plusieurs modèles ;
- Choix argumenté du meilleur modèle ;
- Évaluation avec MAE, RMSE et MAPE ;
- Analyse des erreurs ;
- Discussion des risques métier ;
- Prise en compte du contexte d'infrastructure critique ;
- Réflexion sur la mise en production et le MLOps.

Le modèle retenu est la **Régression Ridge**, car il offre le meilleur compromis entre performance, simplicité, robustesse, interprétabilité et sobriété.

Ce modèle peut aider Néovolt à anticiper la consommation globale, mais il ne doit pas remplacer l'expertise métier.

En production, il devra être utilisé comme un outil d'aide à la décision, intégré à un processus supervisé, gouverné et sécurisé.